Data Mining Homework 1

學號：_____　姓名：_____

使用工具：Weka 3.8.6（Apriori）、Python 3（前處理與驗證）

資料前處理

原始資料共 8,002 筆交易、120 項商品，值為 TRUE/FALSE。直接匯入 Weka 會產生大量 FALSE ⇒ FALSE 的規則。

處理方式（preprocess.py）：將 FALSE 改為缺值「?」，每個屬性只保留 {TRUE}，存成 hw1_2026_preprocessed.arff。Weka 不計入缺值，因此只會產生 TRUE ⇒ TRUE 的規則。

```python
"""Preprocess hw1_2026.csv for Apriori: keep only TRUE (item bought), FALSE -> missing '?'.
Outputs:
  hw1_2026_preprocessed.arff  (Weka input; each attribute is nominal {TRUE}, FALSE becomes '?')
  hw1_2026_preprocessed.csv   (same data in CSV, FALSE replaced by '?')
"""
import csv, sys

src = sys.argv[1] if len(sys.argv) > 1 else "hw1_2026.csv"
with open(src, newline="", encoding="utf-8-sig") as f:
    rows = list(csv.reader(f))
header, data = rows[0], [r for r in rows[1:] if r]
print(f"{len(data)} transactions, {len(header)} items")

def q(name):
    return "'" + name.replace("\\", "\\\\").replace("'", "\\'") + "'"

with open("hw1_2026_preprocessed.arff", "w", encoding="utf-8") as f:
    f.write("@relation hw1_2026_transactions\n\n")
    for h in header:
        f.write(f"@attribute {q(h)} {{TRUE}}\n")
    f.write("\n@data\n")
    for r in data:
        f.write(",".join("TRUE" if v.strip().upper() == "TRUE" else "?" for v in r) + "\n")

with open("hw1_2026_preprocessed.csv", "w", newline="", encoding="utf-8") as f:
    w = csv.writer(f)
    w.writerow(header)
    for r in data:
        w.writerow(["TRUE" if v.strip().upper() == "TRUE" else "?" for v in r])
```

圖 1　preprocess.py

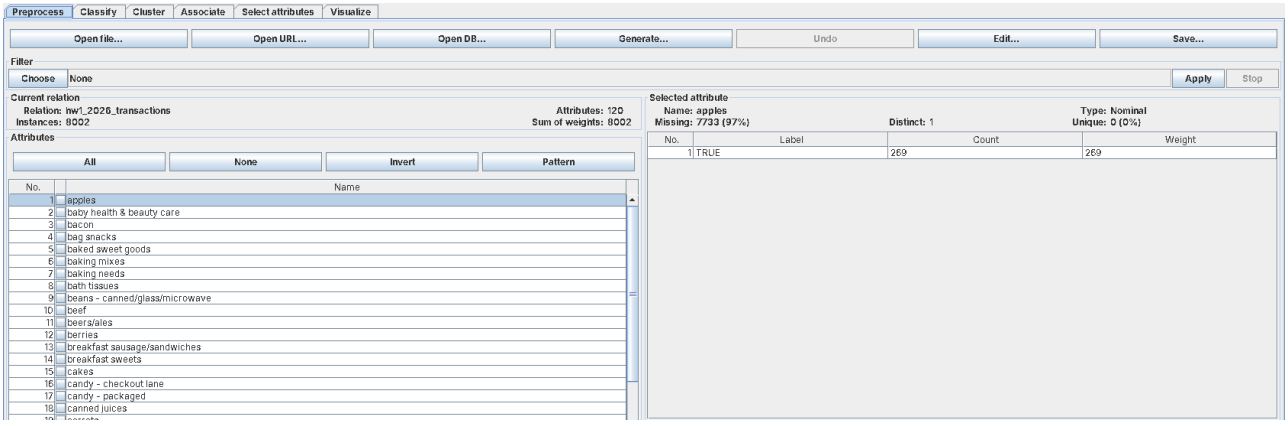


圖 2　匯入 Weka 後：每個屬性只有 TRUE 一個值，其餘為缺值

Q1

(1)

若 A、B 獨立，Pr(A∩B) = Pr(A)Pr(B)，則 Conf(A→B) = Pr(A)Pr(B) / Pr(A) = Pr(B)。所以只要 B 本身很常被購買，即使 A、B 無關，confidence 仍然很高。

例：1,000 人中 200 人買茶，其中 150 人也買咖啡；全體有 900 人買咖啡。Conf(Tea→Coffee) = 0.75 看似很高，但 Pr(Coffee) = 0.9 > 0.75，買茶反而降低買咖啡的機率（負相關）。只看 confidence 會誤判。

本資料中，beers/ales → soft drinks 的 confidence 為 0.29，而 Pr(soft drinks) = 0.306，lift = 0.95 < 1，同樣是負相關。

(2)

不會。Lift = Pr(B|A) / Pr(B)，已除以 Pr(B)，比較的是「有 A 時」與「一般情況下」B 出現的機率。A、B 獨立時 lift 必為 1，不受 Pr(B) 大小影響；上例 lift = 0.83 < 1，可正確看出負相關。

Q2

(1)

Lift > 1 ⇔ Pr(B|A) > Pr(B)：購物籃中有 A 時，B 出現的機率高於平常，A 與 B 正相關。例如 lift = 3 表示買 A 的顧客買 B 的機率是一般顧客的 3 倍，可用於搭配促銷或相鄰陳列。

(2)

- Lift = 1：A、B 獨立，買 A 不影響買 B，搭配銷售沒有額外效果。
- Lift < 1：A、B 負相關，買 A 的人較少買 B，通常是替代品（如兩個品牌的可樂），不適合綁售。

Q3

參數：metric = Confidence，minMetric = 0.9，lowerBoundMinSupport = 0.005，numRules = 10，其餘預設。最終 support = 0.005（40 筆）。

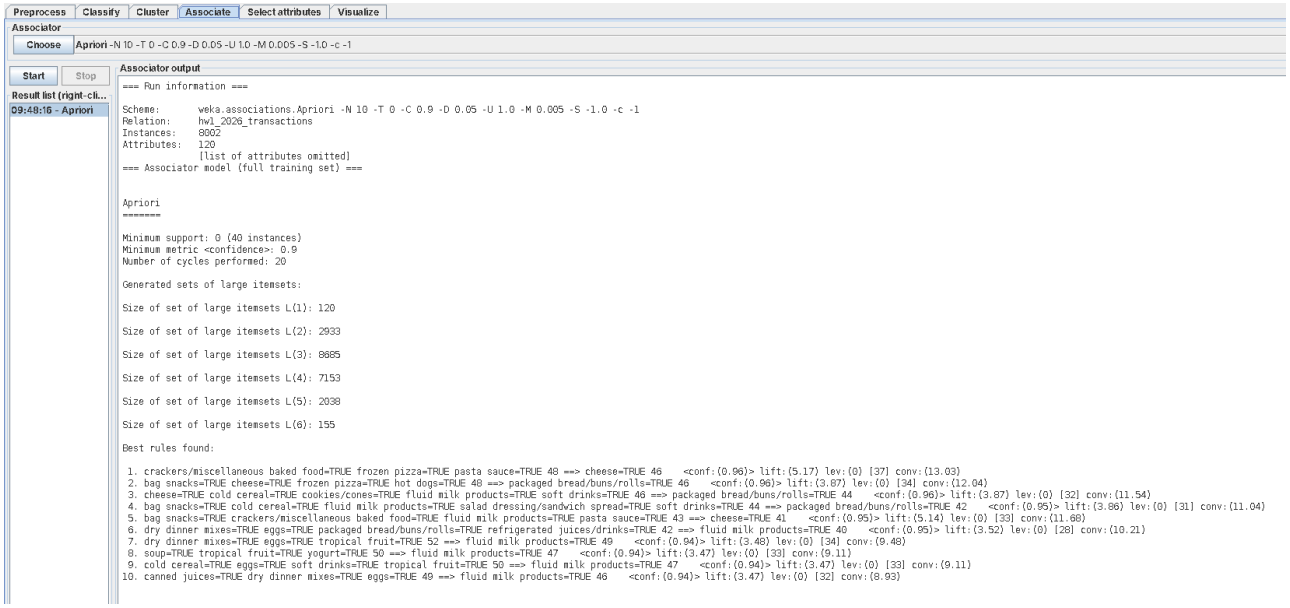


圖 3　Q3 執行結果

(1) 前 10 條 rules

#	LHS（筆數）	RHS（筆數）	Conf	Lift
1	crackers/miscellaneous baked food frozen pizza pasta sauce (48)	cheese (46)	0.96	5.17
2	bag snacks cheese frozen pizza hot dogs (48)	packaged bread/buns/rolls (46)	0.96	3.87
3	cheese cold cereal cookies/cones fluid milk products soft drinks (46)	packaged bread/buns/rolls (44)	0.96	3.87
4	bag snacks cold cereal fluid milk products salad dressing/sandwich spread soft drinks (44)	packaged bread/buns/rolls (42)	0.95	3.86
5	bag snacks crackers/miscellaneous baked food fluid milk products pasta sauce (43)	cheese (41)	0.95	5.14
6	dry dinner mixes eggs packaged bread/buns/rolls refrigerated juices/drinks (42)	fluid milk products (40)	0.95	3.52

#	LHS（筆數）	RHS（筆數）	Conf	Lift
7	dry dinner mixes eggs tropical fruit (52)	fluid milk products (49)	0.94	3.48
8	soup tropical fruit yogurt (50)	fluid milk products (47)	0.94	3.47
9	cold cereal eggs soft drinks tropical fruit (50)	fluid milk products (47)	0.94	3.47
10	canned juices dry dinner mixes eggs (49)	fluid milk products (46)	0.94	3.47

(2) 觀察

後項只有三種熱門商品：fluid milk products（5 條）、packaged bread/buns/rolls（3 條）、cheese（2 條）。前項大致分三類：

- 披薩、義大利麵醬、餅乾 ⇒ 起司（規則 1、5）
- 熱狗、零食、汽水 ⇒ 麵包／熱狗包（規則 2–4）
- 麥片、蛋、水果、果汁、優格 ⇒ 牛奶（規則 6–10）

這些組合在生活中很常見，例如早餐買麥片配牛奶、買熱狗配熱狗麵包、做披薩加起司。不過這些規則的 support 只有 0.5%–0.65%，且後項本身就很熱門，confidence 高有部分是 Q1 所說的原因。

Q4

參數：metric = Confidence，minMetric = 0，只調整 lowerBoundMinSupport。

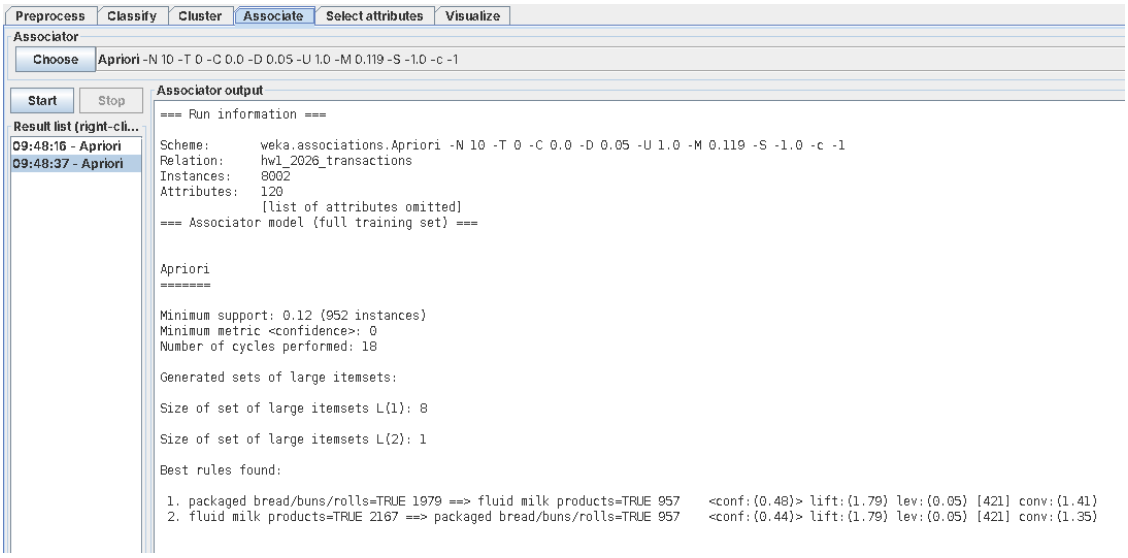


圖 4　lowerBoundMinSupport = 0.119（952 筆），仍有 2 條規則

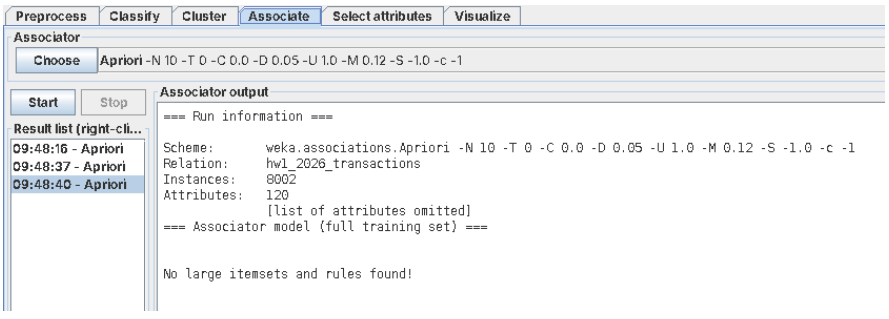


圖 5　lowerBoundMinSupport = 0.120（960 筆），找不到規則

(1)

0.120。

(2)

規則至少需要 2 項商品。support 最高的 2-itemset 為 {fluid milk products, packaged bread/buns/rolls}，共 957 筆（0.1196）。門檻 0.120 換算為 960 筆，已高於 957，因此沒有任何 frequent 2-itemset，也就沒有規則。

此值即為所有規則 support 的上限，代表最常一起購買的兩項商品也只出現在約 12% 的交易中，資料相當稀疏。

Q5

130 / 8002 ≈ 0.01625，設 lowerBoundMinSupport = 0.01625（Weka 換算為 130 筆）、minMetric = 0.75、numRules = 1000，在結果中找第一條由 4 項商品組成的規則。



圖 6　Q5 執行結果（規則 1、2 只有 3 項商品，規則 3 為第一條 4-itemset 規則）

答：{bag snacks, cold cereal, packaged bread/buns/rolls} ⇒ {fluid milk products}，confidence = 140/176 = 0.7955，lift = 2.94。

另以 q5_check.py 列出 39 個 4-itemsets 的全部 546 條規則驗證，結果相同。

```python
"""Q5 cross-check: among 4-itemsets with support count >= 130, find the rules with highest confidence."""
import csv, itertools, collections
rows = list(csv.reader(open("hw1_2026.csv", encoding="utf-8-sig")))
H = rows[0]
T = [frozenset(H[i] for i, v in enumerate(r) if v == "TRUE") for r in rows[1:] if r]
N, MIN = len(T), 130
cnt = collections.Counter()
for k in range(1, 5):
    c = collections.Counter()
    for t in T:
        for s in itertools.combinations(sorted(t), k):
            if k == 1 or all(frozenset(x) in cnt for x in itertools.combinations(s, k - 1)):
                c[frozenset(s)] += 1
    freq = {s: n for s, n in c.items() if n >= MIN}
    cnt.update(freq)
    print(f"L({k}) = {len(freq)}")
L4 = [s for s in cnt if len(s) == 4]
rules = []
for s in L4:
    for r in range(1, 4):
        for a in itertools.combinations(sorted(s), r):
            a = frozenset(a); b = s - a
            conf = cnt[s] / cnt[a]
            rules.append((conf, conf / (cnt[b] / N), sorted(a), sorted(b), cnt[a], cnt[s]))
rules.sort(key=lambda x: -x[0])
for conf, lift, a, b, na, ns in rules[:5]:
    print(f"{a} ({na}) ==> {b} ({ns})  conf={conf:.4f} lift={lift:.2f}")
```

圖 7　q5_check.py

Q6

參數：metric = Lift，minMetric = 3.0，lowerBoundMinSupport = 0.01，numRules = 10。support 下界比 Q3 稍高，以避免極少見的組合排在前面。

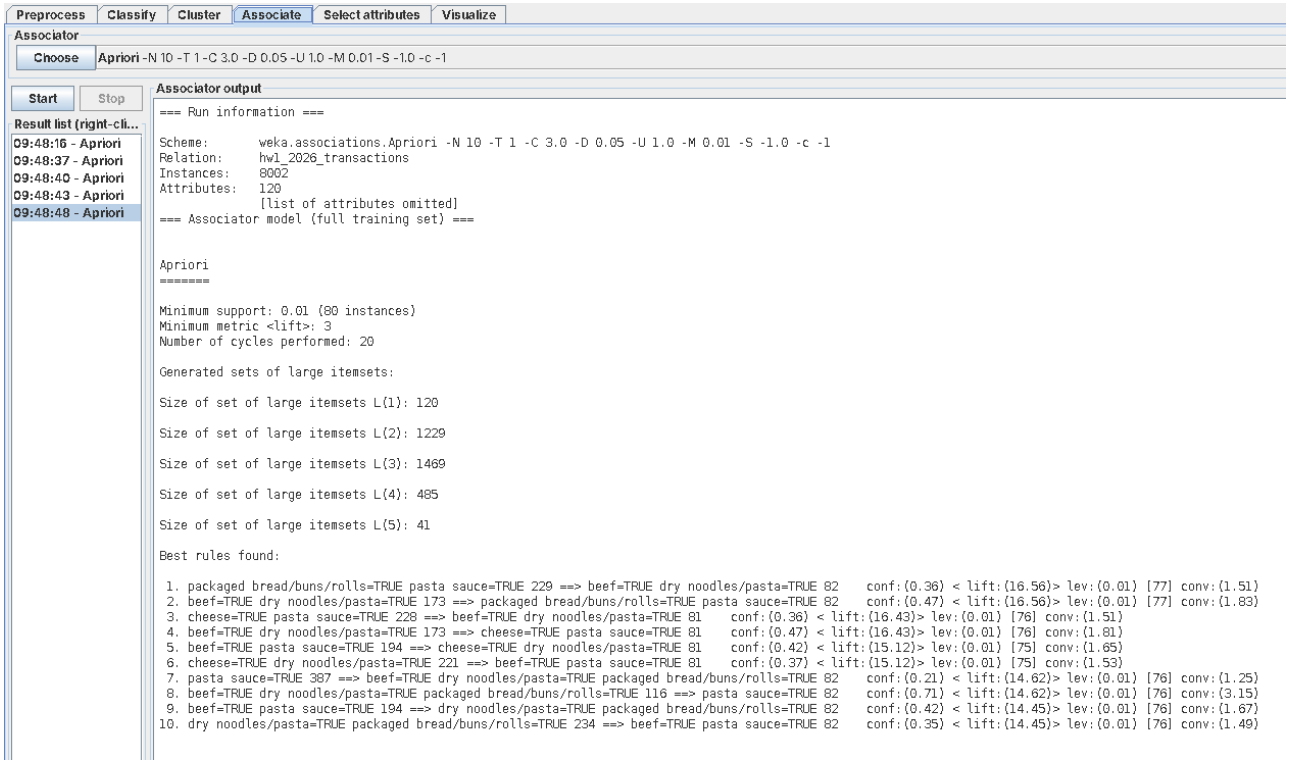


圖 8　Q6 執行結果

前 10 條 rules

#	LHS（筆數）	RHS（筆數）	Conf	Lift
1	packaged bread/buns/rolls pasta sauce (229)	beef dry noodles/pasta (82)	0.36	16.56
2	beef dry noodles/pasta (173)	packaged bread/buns/rolls pasta sauce (82)	0.47	16.56
3	cheese pasta sauce (228)	beef dry noodles/pasta (81)	0.36	16.43
4	beef dry noodles/pasta (173)	cheese pasta sauce (81)	0.47	16.43
5	beef pasta sauce (194)	cheese dry noodles/pasta (81)	0.42	15.12
6	cheese dry noodles/pasta (221)	beef pasta sauce (81)	0.37	15.12

#	LHS（筆數）	RHS（筆數）	Conf	Lift
7	pasta sauce (387)	beef dry noodles/pasta packaged bread/buns/rolls (82)	0.21	14.62
8	beef dry noodles/pasta packaged bread/buns/rolls (116)	pasta sauce (82)	0.71	14.62
9	beef pasta sauce (194)	dry noodles/pasta packaged bread/buns/rolls (82)	0.42	14.45
10	dry noodles/pasta packaged bread/buns/rolls (234)	beef pasta sauce (82)	0.35	14.45

與 Q3 的差異

	Q3（Confidence）	Q6（Lift）
商品	早餐、熱狗、披薩等多種組合	集中在牛肉＋義大利麵＋義大利麵醬（＋起司、麵包）
後項	單一熱門商品	2–3 項、較不熱門的商品
Conf	0.94–0.96	0.21–0.71
Lift	3.47–5.17	14.45–16.56
形式	各條不同	A⇒B、B⇒A 成對出現（lift 對稱）

Confidence 偏向後項為熱門商品的規則；lift 排除了熱門程度的影響，找出的是互補性強的組合（同一道菜的食材），confidence 雖低，但更適合用於搭配促銷。

Q7

- 工具：Weka 3.8.6 Explorer 的 Apriori（Associate 頁面）；Python 3 用於前處理（preprocess.py）與 Q5 驗證（q5_check.py）。
- 前處理：FALSE 改為缺值，屬性設為 {TRUE}，輸出 .arff 檔。
- 參數：如下表，其餘（delta = 0.05、upperBoundMinSupport = 1.0）為預設值。

題目	metric	minMetric	lowerBoundMinSupport	numRules
Q3	Confidence	0.9	0.005	10
Q4	Confidence	0	0.119 / 0.120	10
Q5	Confidence	0.75	0.01625	1000
Q6	Lift	3.0	0.01	10

- Q4 先用 Python 算出最大 2-itemset support（957 筆），再於 Weka 驗證 0.119 與 0.120。